Technical report

Team:

- 龚平，Ping Gong，PB17030808，贡献55%
- 罗极羽，Jiyu Luo，PB17111656，贡献45%

note:

- 本文档使用`Typora`撰写，其他markdown解释器可能存在编译错误。
- 本项目以上传github，并将于19号00：00开放。

Layer Design

在本实验中，使用了四种网络结构:

Conv2d、Linear、LSTM、elu

Conv2d

- forward 原理 & 实现

  直接将输入图像与卷积核进行二维卷积

  利用conv2d来实现卷积运算:

  ```
  F.conv2d(input, self.weight, self.bias, self.stride,
                          self.padding, self.dilation, self.groups)
  ```

- backward 原理

  用一个简单的例子说明其原理（暂不考虑stride，下文补充）：

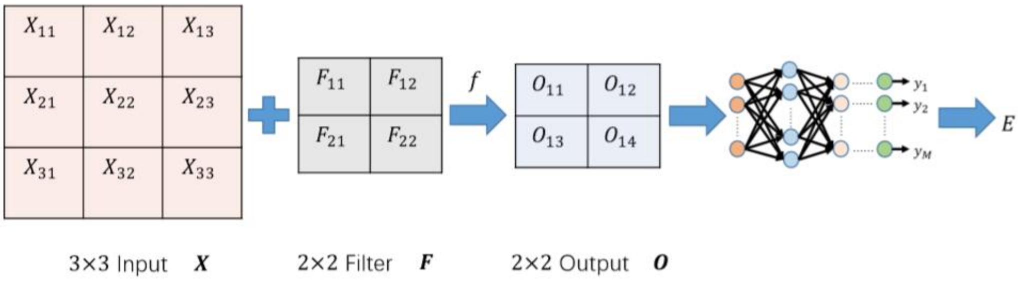

首先求 E ***对权重*** F ***的梯度***:

$$\frac{\partial E}{\partial F_{11}} = \frac{\partial E}{\partial \mathbf{O}}^{\top} \frac{\partial \mathbf{O}}{\partial F_{11}} = \frac{\partial E}{\partial O_{11}} X_{11} + \frac{\partial E}{\partial O_{12}} X_{12} + \frac{\partial E}{\partial O_{21}} X_{21} + \frac{\partial E}{\partial O_{22}} X_{22}$$

以此类推，可以看出， E 对权重 F 的梯度也可以通过卷积运算求出

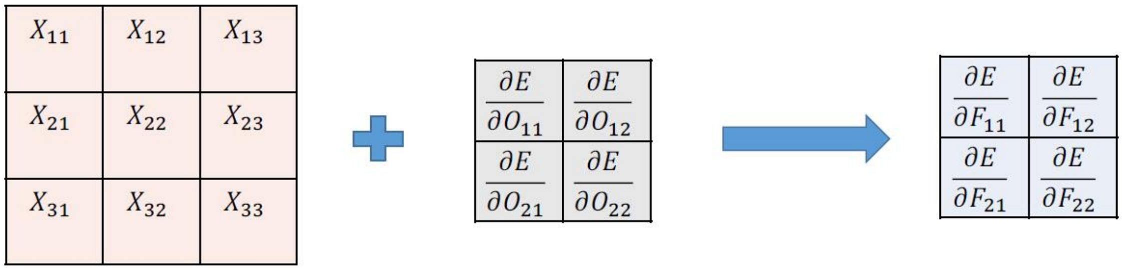

同理，考虑 E ***对输入*** X ***的梯度***:

$$\frac{\partial E}{\partial X_{11}} = \frac{\partial E}{\partial \mathbf{O}}^{\top} \frac{\partial \mathbf{O}}{\partial X_{11}} = \frac{\partial E}{\partial O_{11}} F_{11} + \frac{\partial E}{\partial O_{12}} 0 + \frac{\partial E}{\partial O_{21}} 0 + \frac{\partial E}{\partial O_{22}} 0$$

以此类推，我们发现可以将卷积核（权重F）旋转180°，并与 $\frac{\partial E}{\partial \mathbf{O}}$ （补0）进行卷积从而得到结果

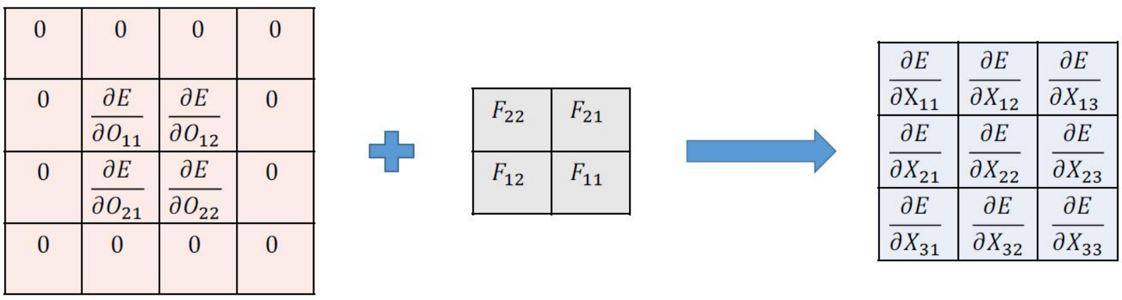

而当$stride > 1$ ***时***，需要将原本的卷积操作换为空洞卷积，dilation 的值即为 stride（将卷积核设为为1×1即可证明）

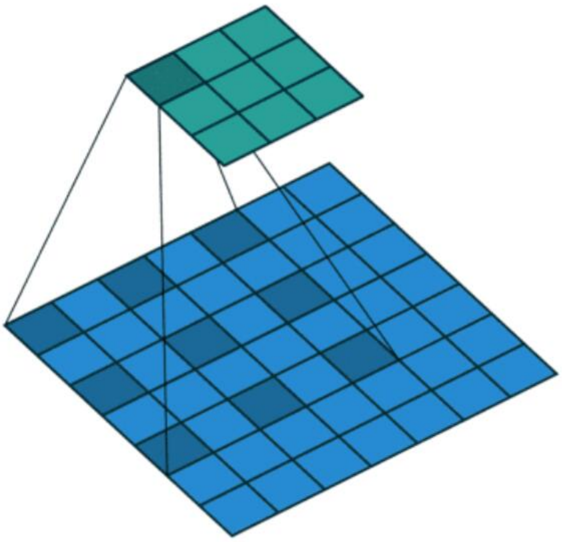

- backward 实现

  记O为卷积结果，W为权重（卷积核），X为输入，b为偏置

  权重的梯度： 通过[F.conv2d]来实现卷积运算（设置空洞dilation）

  输入的梯度： 通过反卷积函数[conv_transpose2d]实现（反卷积的理解参考[这里]，原理上文已描述过）

```
conv_for_back = F.conv_transpose2d(top_grad_t,
self.weight,torch.zeros(self.in_channels), self.stride, self.padding,
(self.input[i].shape[2]-top_grad.shape[2])%2, self.groups,self.dilation)
```

  偏置的梯度： 直接求和即可。

$$\frac{\partial Loss}{\partial b} = \sum \frac{\partial Loss}{O_{ij}}$$

Linear

- forward 原理 & 实现

$$\mathbf{y} = \mathbf{x}W^{\top} + b$$

  利用[F.linear]函数即可

- backward 原理 & 实现

  权重的梯度：

$$\frac{\partial Loss}{\partial W} = \frac{\partial Loss}{\partial \mathbf{y}}^{\top}\mathbf{x}$$

  偏置的梯度：

$$\frac{\partial Loss}{\partial \mathbf{b}} = \frac{\partial Loss}{\partial \mathbf{y}}$$

  输入的梯度：

$$\frac{\partial Loss}{\partial \mathbf{x}} = \frac{\partial Loss}{\partial \mathbf{y}}\mathbf{W}$$

  以上梯度只需通过$torch.matmul, torch.add$函数即可求出。

LSTM

在使用深度学习处理时序问题时，RNN时最常使用的模型之一。RNN能够有效的将之前的时间片信息用于计算当前时间片的输入。其中Long Short Term Memory (LSTM)是一种常见且有效的神经网络。由于`Riverraid-v0`虽然`action`是离散的，但是其状态在时间尺度上有非常强的相关性，所以考虑使用LSTM进行训练，能取得不错的成果。

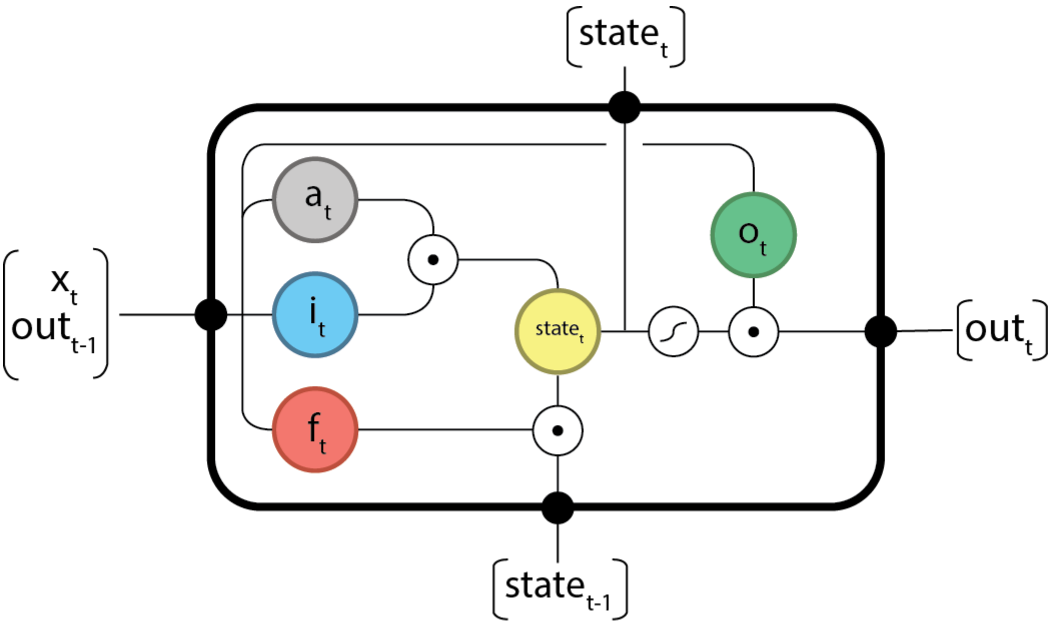

假设对`t`轮，对LSTM输入为$\mathbf{x}_t$，$\mathbf{h}_{t-1}$、$\mathbf{c}_{t-1}$，下面我们考虑$Forward$和$Backward$

- Forward

  LSTM内部由四个门构成，涉及到五个运算，分别是向量元素乘、向量和、$tanh$、σ以及四个门电路

  对 $tanh(\mathbf{x})=\frac{e^x-e^{-x}}{e^x+e^{-x}}=\frac{e^{2x}-1}{e^{2x}+1}=\frac{1-e^{-2x}}{1+e^{-2x}}$, 对tanh计算同样存在上溢或者下溢的问题。因此对正数，我们倾向于使用$\frac{1-e^{-2x}}{1+e^{-2x}}$计算；对于负数，我们倾向于使用$\frac{e^x-e^{-x}}{e^x+e^{-x}}$以提高计算精度

```
#伪代码
if x > 0:
    tanh = (1 - exp(-2 * x)) / (1 +  exp(-2 * x))
else:
    tanh = (exp(2 * x) - 1) / (exp(2 * x) + 1)

#实际代码
def tanh(value):
    value = value.double()
    e_p = torch.exp(value.mul(2))
    e_n = torch.exp(value.mul(-2))
    tanh_n = (e_p - 1) / (e_p + 1)
    tanh_p = (1 - e_n) / (1 + e_n)
    return torch.where(value > 0, tanh_p, tanh_n).float()
```

  对$\sigma(x)=\frac{e^x}{1+e^x}$同样也存在这个问题，因而我们要区分正负数，进行单独计算，以提高精度

```python
        def sigmoid(value):
            value = value.double()
            sigmoid_value_p = torch.exp(-value).add(1).pow(-1)
            exp_value = torch.exp(value)
            sigmoid_value_n = exp_value.div(exp_value.add(1))
            return torch.where(value > 0, sigmoid_value_p,
sigmoid_value_n).float()
```

完成上诉设计，即可完成LSTM $Forward$设计，四个门:

$$\begin{aligned}
\text{Input activation:} & \\
& a_t = \tanh(W_a \cdot x_t + U_a \cdot out_{t-1} + b_a) \\
\text{Input gate:} & \\
& i_t = \sigma(W_i \cdot x_t + U_i \cdot out_{t-1} + b_i) \\
\text{Forget gate:} & \\
& f_t = \sigma(W_f \cdot x_t + U_f \cdot out_{t-1} + b_f) \\
\text{Output gate:} & \\
& o_t = \sigma(W_o \cdot x_t + U_o \cdot out_{t-1} + b_o)
\end{aligned}$$

因此对当前LSTM最终输出为:

$$\begin{aligned}
\text{Input activation:} & \\
& a_t = \tanh(W_a \cdot x_t + U_a \cdot out_{t-1} + b_a) \\
\text{Input gate:} & \\
& i_t = \sigma(W_i \cdot x_t + U_i \cdot out_{t-1} + b_i) \\
\text{Forget gate:} & \\
& f_t = \sigma(W_f \cdot x_t + U_f \cdot out_{t-1} + b_f) \\
\text{Output gate:} & \\
& o_t = \sigma(W_o \cdot x_t + U_o \cdot out_{t-1} + b_o)
\end{aligned}$$

```python
        def forward(input, hidden):
            hx, cx = hidden
            gates = F.linear(input, w_ih, b_ih) + F.linear(hx, w_hh, b_hh)
            ingate, forgetgate, cellgate, outgate = gates.chunk(4, 1)
            ingate     = F.sigmoid(ingate)
            forgetgate = F.sigmoid(forgetgate)
            cellgate   = F.tanh(cellgate)
            outgate    = F.sigmoid(outgate)
            cy = (forgetgate * cx) + (ingate * cellgate)
            hy = outgate * F.tanh(cy)
            return hy, cy
```

- Backward

  对LSTM backward相对而言就要非常复杂了，首先我们先对σ和$tanh$两个函数完成其对应的求导

  $\frac{\partial \sigma(x)}{\partial x} = \sigma(x)(1 - \sigma(x))$

$\frac{\partial tanh(x)}{\partial x} = 1 - tanh^2(x)$

根据LSTM前向传播计算LSTM的方向传播:

$$
\begin{aligned}
\delta out_t &= \Delta_t + \Delta out_t \\
\delta state_t &= \delta out_t \odot o_t \odot (1 - \tanh^2(state_t)) + \delta state_{t+1} \odot f_{t+1} \\
\delta a_t &= \delta state_t \odot i_t \odot (1 - a_t^2) \\
\delta i_t &= \delta state_t \odot a_t \odot i_t \odot (1 - i_t) \\
\delta f_t &= \delta state_t \odot state_{t-1} \odot f_t \odot (1 - f_t) \\
\delta o_t &= \delta out_t \odot \tanh(state_t) \odot o_t \odot (1 - o_t) \\
\delta x_t &= W^T \cdot \delta gates_t \\
\Delta out_{t-1} &= U^T \cdot \delta gates_t
\end{aligned}
$$

最终我们更新的权重为:

$$
\begin{aligned}
\delta W &= \sum_{t=0}^{T} \delta gates_t \otimes x_t \\
\delta U &= \sum_{t=0}^{T-1} \delta gates_{t+1} \otimes out_t \\
\delta b &= \sum_{t=0}^{T} \delta gates_{t+1}
\end{aligned}
$$

实现部分非常长，这里仅放实现代码的链接 LSTM backward

elu

激活函数elu非常简单

- Forward:

$$
f(x) = \begin{cases} x, & \text{if } x > 0; \\ \alpha(\exp(x) - 1) & \text{if } x \le 0 \end{cases}
$$

- Backward:

$$
\frac{\partial f(x)}{\partial x} = \begin{cases} 1, & \text{if } x > 0; \\ \alpha \exp(x) & \text{if } x \le 0 \end{cases}
$$

在本实验，使用 $\alpha = 1$.

Algothrim --A3C

intro & theory

A3C,即 Asynchronous advantage actor-critic，异步优势动作评价算法。在具体了解A3C前，我们要先了解一下Actor-Critic 框架和A2C 算法。

- *DQN vs A3C*

  较为复杂的游戏中，DQN一次只能探索很少的空间，从而更新Q值的速度很慢，需要很长时间的训练才能达到不错的表现。

  相比之下，A3C算法将policy-base和value-based相结合，一方面避免了蒙特卡洛算法（policy-based）方差较大的问题，另一方面在训练效果和速度上也优于DQN（value-based）。

- **Actor-Critic**

  Actor-Critic 包括两部分：Actor 负责生成动作(Action)并和环境交互。而Critic负责评估Actor的表现，并指导Actor下一阶段的动作。

  Actor（policy based）：即策略$\pi(a|s)$，我们用神经网络进行近似（s = state，a = action）

  $$\pi_\theta(s,a) \approx \pi(a|s)$$

  Critic（value based）：即价值函数$v_\pi(s)$和$q_\pi(s,a)$，同样用神经网络近似

  $$v(s,w) \approx v_\pi(s)$$
  $$q(s,a,w) \approx q_\pi(s,a)$$

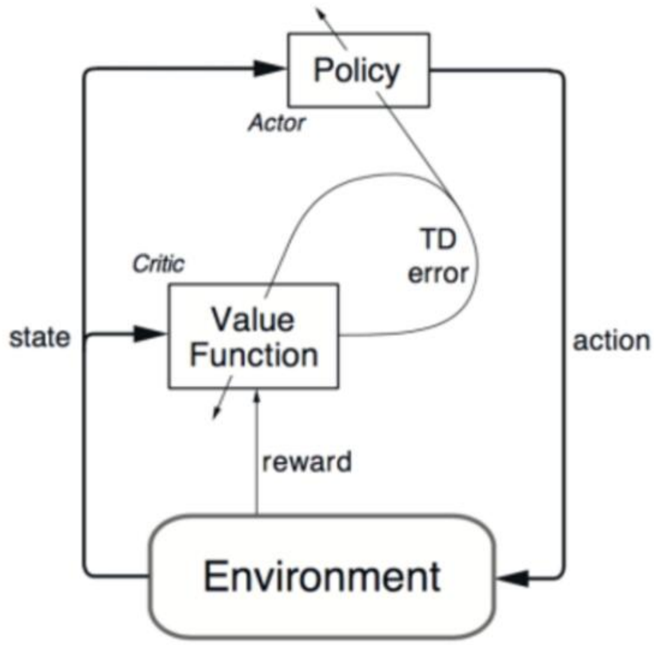

接下来考虑如何对参数进行更新，来优化策略

假设需要优化的目标是当前策略下，初始状态reward的期望：

$$\rho(\pi) = E\left(\sum_{t=1}^{\infty} \gamma^{t-1} r_t \mid s_0, \pi\right)$$

我们有如下结论（证明见此论文），其中$Q^\pi(s,a)$可以取不同的价值函数:

$$\frac{\partial \rho}{\partial \theta} = \sum_s d^\pi(s) \sum_a \frac{\partial \pi_\theta(s,a)}{\partial \theta} Q^\pi(s,a)$$

再由等式$\frac{\partial \pi_\theta(s,a)}{\partial \theta} = \pi_\theta(s,a) \nabla_\theta \log \pi_\theta(s,a)$ 可得

$$\frac{\partial \rho}{\partial \theta}=\mathbb{E}_{\pi_\theta}[\nabla_\theta \log \pi_\theta(s,a) Q^\pi(s,a)]$$

因此，策略的参数更新公式为

$$\theta=\theta+\alpha \nabla_\theta \log \pi_\theta(s,a) Q^\pi(s,a)$$

- A2C (Advantage Actor Critic)

  在上述框架中，采用优势函数 $A_\pi(s,a)=Q_\pi(s,a)-V_\pi(s)$ 作为 Critic的价值函数，就得到A2C算法。从而策略的更新公式变为

  $$\theta=\theta+\alpha \nabla_\theta \log \pi_\theta(s,a) A_\pi(s,a)$$

  A2C vs AC:

  当优势函数大于0，说明此该动作优于平均动作，反之则不如平均动作。这样可以更好的处理动作价值函数全正或者全负的情况。

  相较于累计回报，优势函数的方差会更小。

- A3C的改进和具体算法

  在传统的A2C上，A3C采用了异步的方式，从而打破数据间的相关性，解决了AC算法难以收敛的问题：

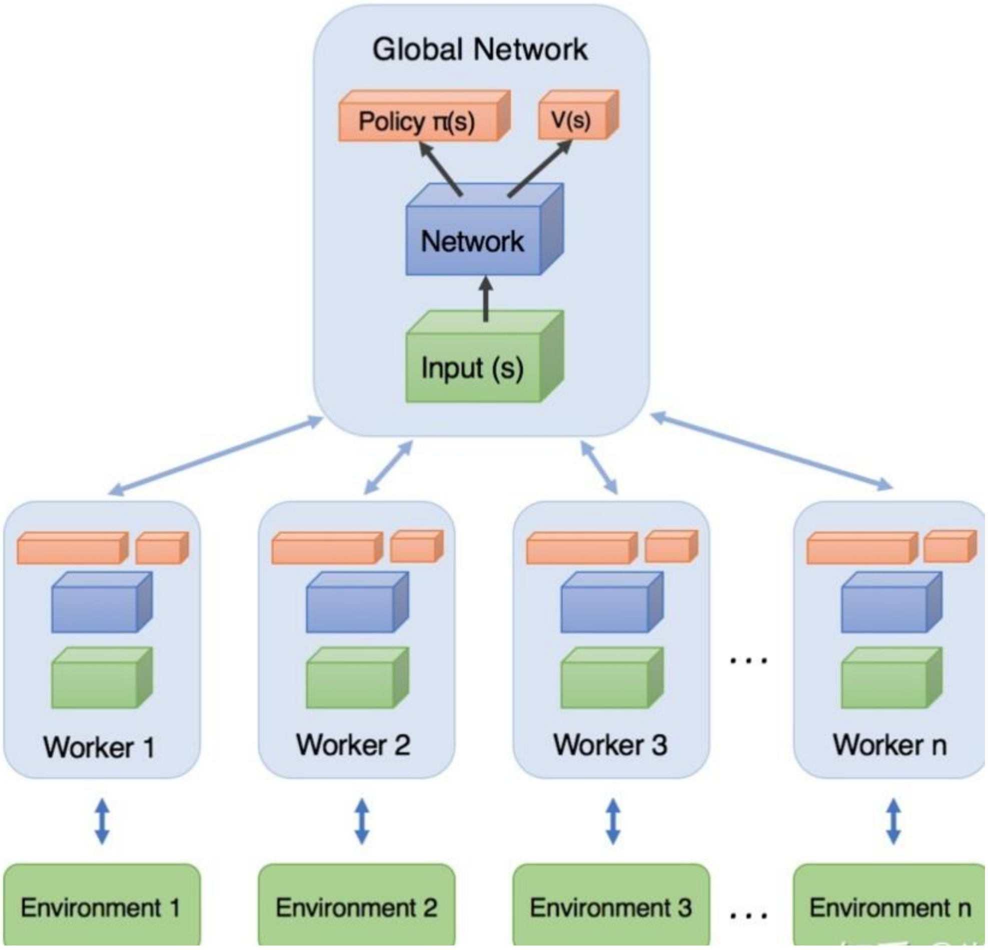

下面是A3C的伪代码

Algorithm S3 Asynchronous advantage actor-critic - pseudocode for each actor-learner thread.

// Assume global shared parameter vectors θ and θ_v and global shared counter $T = 0$
// Assume thread-specific parameter vectors θ' and θ'_v
Initialize thread step counter $t \leftarrow 1$
repeat
  Reset gradients: $d\theta \leftarrow 0$ and $d\theta_v \leftarrow 0$.
  Synchronize thread-specific parameters $\theta' = \theta$ and $\theta'_v = \theta_v$
  $t_{start} = t$
  Get state s_t
  repeat
    Perform a_t according to policy $\pi(a_t|s_t;\theta')$
    Receive reward r_t and new state s_{t+1}
    $t \leftarrow t + 1$
    $T \leftarrow T + 1$
  until terminal s_t **or** $t - t_{start} == t_{max}$
  $R = \begin{cases} 0 & \text{for terminal } s_t \\ V(s_t, \theta'_v) & \text{for non-terminal } s_t \text{// Bootstrap from last state} \end{cases}$
  for $i \in \{t-1, \ldots, t_{start}\}$ **do**
    $R \leftarrow r_i + \gamma R$
    Accumulate gradients wrt θ': $d\theta \leftarrow d\theta + \nabla_{\theta'} \log \pi(a_i|s_i;\theta')(R - V(s_i;\theta'_v))$
    Accumulate gradients wrt θ'_v: $d\theta_v \leftarrow d\theta_v + \partial\left(R - V(s_i;\theta'_v)\right)^2 / \partial\theta'_v$
  end for
  Perform asynchronous update of θ using $d\theta$ and of θ_v using $d\theta_v$.
until $T > T_{max}$

Model Design

本小结将解释模型是如何设计的，整个模型如下图所示，共有七层。

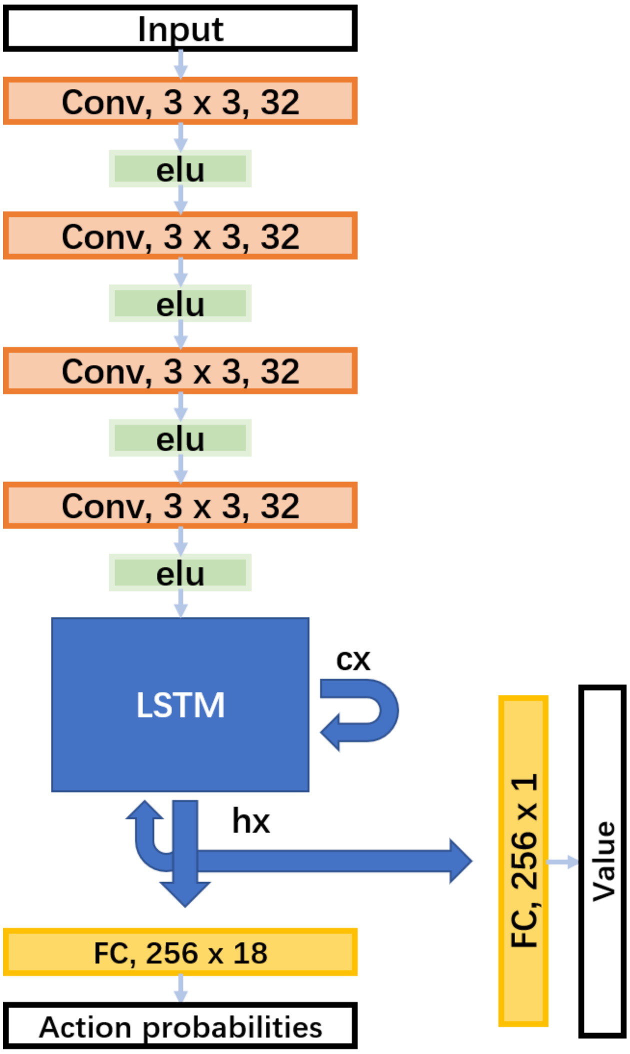

由于输入的state，实际上是图像信息，因而我们使用四层卷积层，来提取图片的信息，并使用`elu`作为激活函数。

```
        x = F.elu(self.conv1.forward(inputs))
        x = F.elu(self.conv2.forward(x))
        x = F.elu(self.conv3.forward(x))
        x = F.elu(self.conv4.forward(x))
```

考虑到，输入的state变化在时间尺度上有非常高的关联性，我们采用`LSTM`来提取时间尺度上的变化特征，使得网络能更好的提取state的特征。

```
        x = x.view(-1, 32 * 3 * 3)
        hx, cx = self.lstm.forward(x, (hx, cx))
```

最后是采用两个全连接层，其中一个输出`action advantage value`，另外一个输出`state value`。

```
        #state value
        self.critic_linear.forward(x)
        #advantage value
        self.actor_linear.forward(x)
```

在前向传播过程中，我们要保存一些中间结果，这里就不展示这部分结构了。

整个模型forward过程为：

```
        def forward(self, inputs):
                inputs, (hx, cx) = inputs
                x = F.elu(self.conv1.forward(inputs))
                x = F.elu(self.conv2.forward(x))
                x = F.elu(self.conv3.forward(x))
                x = F.elu(self.conv4.forward(x))
                # x.shape = 1, 32, 3, 3
                x = x.view(-1, 32 * 3 * 3)
                # x.shape = 1, 288
                hx, cx = self.lstm.forward(x, (hx, cx))
                x = hx
                return self.critic_linear.forward(x),
self.actor_linear.forward(x), (hx, cx)
```

由于我们已经完成各层反向传播的计算，所以对模型的反向传播直接为各层的组装：

```
        def backward(self, top_grad_value, top_grad_logit):
                grad_inputs = []

                grad_critic_linear = self.critic_linear.backward(top_grad_value)
                grad_actor_liner = self.actor_linear.backward(top_grad_logit)

                top_grad_h = []

                for i in range(len(grad_critic_linear)):
                    top_grad_h.append(grad_critic_linear[i] +
grad_actor_liner[i])

                top_grad_c = [0] * len(grad_critic_linear)
```

```
            top_grad_conv4, _, _ = self.lstm.backward(top_grad_h,
top_grad_c)

            top_grad_conv4 = [element.view(-1, 32, 3, 3) for element in
top_grad_conv4]

            top_grad_conv4 = grad_elu(top_grad_conv4, self.y4)
            top_grad_conv3 = self.conv4.backward(top_grad_conv4)

            top_grad_conv3 = grad_elu(top_grad_conv3, self.y3)
            top_grad_conv2 = self.conv3.backward(top_grad_conv3)

            top_grad_conv2 = grad_elu(top_grad_conv2, self.y2)
            top_grad_conv1 = self.conv2.backward(top_grad_conv2)

            top_grad_conv1 = grad_elu(top_grad_conv1, self.y1)
            grad_inputs = self.conv1.backward(top_grad_conv1)

            return grad_inputs
```

Inputs Normalization

由于输入的是图像信息，具有高度信息冗余，所以我们需要对图像进行一定操作，提高信息密度减少计算量，并规约化，核心操作为

1. crop & resize

   首先先裁掉边框信息，然后分两次resize，以提高保留的信息密度

   ```
       frame = frame[34:34 + 160, :160]
       frame = cv2.resize(frame, (80, 80))
       frame = cv2.resize(frame, (42, 42))
   ```

2. channel merge

   同时由于图像是RGB图像，我们并不需要颜色信息，因而可以对channel进行合并，减小计算量

   ```
       frame = frame.mean(2, keepdims=True)
   ```

3. normalize

   我们需要将输入数据调整为正态分布，但是由于并不清楚，总体方差和平均值是多少，因而我们采用采样估计的策略。

   ```
       frame *= (1.0 / 255.0)

       class NormalizedEnv(gym.ObservationWrapper):
           def __init__(self, env=None):
               super(NormalizedEnv, self).__init__(env)
               self.state_mean = 0
               self.state_std = 0
               self.alpha = 0.9999
               self.num_steps = 0

           def observation(self, observation):
               self.num_steps += 1
   ```

```python
            #更新均值
            self.state_mean = self.state_mean * self.alpha + \
                observation.mean() * (1 - self.alpha)
            #更新标准差
            self.state_std = self.state_std * self.alpha + \
                observation.std() * (1 - self.alpha)

            unbiased_mean = self.state_mean / (1 - pow(self.alpha,
self.num_steps))
            unbiased_std = self.state_std / (1 - pow(self.alpha,
self.num_steps))

            return (observation - unbiased_mean) / (unbiased_std + 1e-8)
```

Reward design

根据[Welcome to Deep Reinforcement Learning Part 1 : DQN]()采用Clipping rewards 设计可以提高模型性能，由于`Riverraid-v0`中reward全为非负，因而我们可以clip reward为 0 和 1。

```python
        reward = max(min(reward, 1), -1)
```

Loss Compute

$reward_i$ 为单步的reward；v_i为Critic得到的预估价值；$logprob_i$为选择的action的概率的对数（经过softmax和log处理）

$$Loss = L_{value} + L_{policy}$$

首先获得一个episode(n步)中每个state的预期Reward：

$$R_k = \sum_{i=k}^{n} \gamma^{i-k} reward_i$$

然后得到L_{value}：

$$L_{value} = \alpha_{value} \frac{1}{2} \sum_{i=1}^{n} (R_i - v_i)^2$$

接着计算单步优势函数：

$$\Delta_i = reward_i + \gamma v_{i+1} - v_i$$

和每个state的优势函数：

$$gae_k = \sum_{i=1}^{n} (\lambda\gamma)^{k-i} \Delta_i$$

最后得到L_{policy}（对应上文提到的参数更新公式）：

$$L_{policy} = -\sum_{i=1}^{n} gae_i * logprob_i$$

考虑到平衡action，避免过于集中，我们引入第i步policy的熵$Entropy_i$，最终得到

$$L_{policy} = -\sum_{i=1}^{n} gae_i * logprob_i - \alpha_{entropy}\sum_{i=1}^{n} Entropy_i$$

$$Loss = L_{value} + L_{policy} = \alpha_{value}\frac{1}{2}\sum_{i=1}^{n}(R_i - v_i)^2 - \sum_{i=1}^{n} gae_i * logprob_i - \alpha_{entropy}\sum_{i=1}^{n} Entropy_i$$

- Loss backward

  以单步为例，最后求和即可

  记$value$ 为$Critic$估计的value值，$logit$为$Actor$估计得到的policy

  我们只需求得$\frac{\partial L}{\partial \textbf{value}}$和$\frac{\partial L}{\partial \textbf{logit}}$

  事实上，这只涉及最基础的求导，具体的公式的推导可以参考[这里P41]()

  首先我们有

$$p_i = \frac{e^{logit_i}}{\sum_k e^{logit_k}}$$

$$logprob = log(p_i)$$

  所以

$$\frac{\partial logprob}{\partial logit_j} = \begin{cases} 1 - p_i & i = j \\ -p_j & i \neq j \end{cases}$$

  Entropy同理

Update Gradient

我们使用`Adam`优化器进行梯度更新：

算法伪代码：

Algorithm 1: *Adam*, our proposed algorithm for stochastic optimization. See section 2 for details, and for a slightly more efficient (but less clear) order of computation. g_t^2 indicates the elementwise square $g_t \odot g_t$. Good default settings for the tested machine learning problems are $\alpha = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$ and $\epsilon = 10^{-8}$. All operations on vectors are element-wise. With β_1^t and β_2^t we denote β_1 and β_2 to the power t.

Require: α: Stepsize
Require: $\beta_1, \beta_2 \in [0, 1)$: Exponential decay rates for the moment estimates
Require: $f(\theta)$: Stochastic objective function with parameters θ
Require: θ_0: Initial parameter vector
  $m_0 \leftarrow 0$ (Initialize 1st moment vector)
  $v_0 \leftarrow 0$ (Initialize 2nd moment vector)
  $t \leftarrow 0$ (Initialize timestep)
  while θ_t not converged **do**
    $t \leftarrow t + 1$
    $g_t \leftarrow \nabla_\theta f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)
    $m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)
    $v_t \leftarrow \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$ (Update biased second raw moment estimate)
    $\widehat{m}_t \leftarrow m_t/(1 - \beta_1^t)$ (Compute bias-corrected first moment estimate)
    $\widehat{v}_t \leftarrow v_t/(1 - \beta_2^t)$ (Compute bias-corrected second raw moment estimate)
    $\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \widehat{m}_t/(\sqrt{\widehat{v}_t} + \epsilon)$ (Update parameters)
  end while
  return θ_t (Resulting parameters)

实现过程参考[torch.optim.adam]()，实现部分为[my_optim.py]()

Others

整个目录结构如下：

```
├── A3C                     #A3C实现代码
|   ├── envs.py             #处理输入数据
|   ├── layers.py           #每层网络设计
|   ├── my_main.py
|   ├── my_model.py         #模型设计
|   ├── my_optim.py         #optimizer实现
|   ├── my_test.py          #测试进程
|   └── my_train.py         #训练进程
├── PB17111656.py           #对外测试接口
├── figures
├── log                     #训练日志存放
├── model                   #model存放
├── report.md
├── requirement.txt
├── rl_configs.py
└── todo.txt
```

超参数设计（参考pytorch-a3c）：

```python
    class config(object):
        def __init__(self):
            self.lr = 0.0001                        #学习率
            self.gamma = 0.99                       #A3C 计算loss所用参数
            self.gae_lambda = 1.00
            self.entropy_coef = 0.01
            self.value_loss_coef = 0.5
            self.max_grad_norm = 50                 #用于clip gradient, 以防梯度爆炸
            self.seed = 1
            self.num_processes = 23                 #训练使用进程
            self.num_steps = 20                     #每num_steps个acitons, 训练进程对中心模型进行一次参数更新
            self.max_step_length = 1000000          #最大训练步长
            self.env_name = 'Riverraid-v0'          #训练任务
            self.model_path = './model/'            #模型存储位置
            self.test_interval = 20                 #测试进程每隔20秒, 测试一次当前中心模型性能
```

Result

A3C具有优秀的训练速度和性能，训练二十四小时即可完成收敛，平均100-episode reward为10000+。

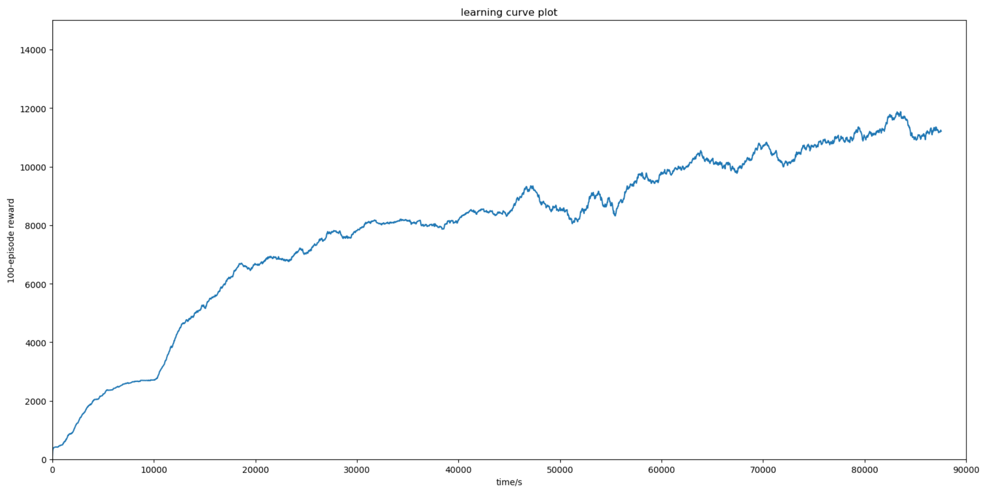

单局演示：

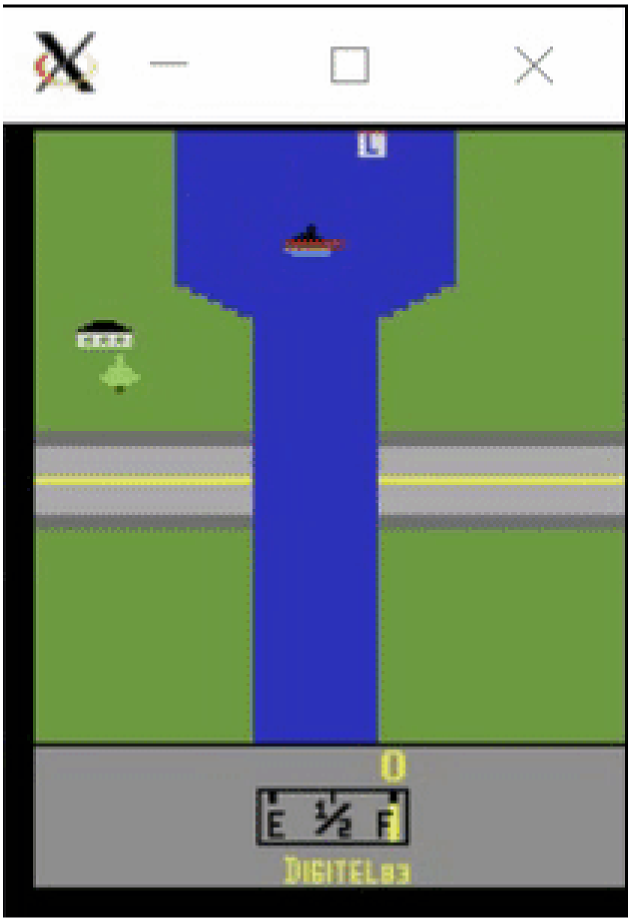

Reference

[pytorch-a3c]()

[torch.optim.adam]()

[Welcome to Deep Reinforcement Learning Part 1 : DQN]()

[百度百科：卷积神经网络]()

[pytorch官方文档：nn.functional]()

[机器学习课件/Lec10.pdf]()

[空洞卷积理解]

[怎样通俗易懂地解释反卷积？]

[Policy Gradient Methods for Reinforcement Learning with Function Approximation]

[AC、A2C、A3C算法]

[Actor-Critic]

[深度强化学习算法 A3C]

[机器学习课件/Lec09.pdf]

[Intuitive RL: Intro to Advantage-Actor-Critic (A2C)]